Machine Learning For Software Engineering

Marco Lorenzini – 0353515

Agenda

01 Introduzione

02 Obiettivo

03 Progettazione

04 Risultati

05 Assunzioni &
Minacce alla validità

06 Conclusioni

01 Introduzione – cosa è il testing?

Il testing è un processo di convalida del software effettuato attraverso metodi sistematici (white-box, black-box) per individuare incongruenze tra specifica formale, implementazione e comportamento atteso.
Ma quanto costa?

Tempo di sviluppo

20-40% del tempo di sviluppo è dedicato al testing

Costo medio annuo

23% del budget annuale IT di un'organizzazione è dedicato al testing

02 Obiettivo

Ottimizzare il testing identificando classi ad alto rischio di bug tramite l'utilizzo di Modelli di **Machine Learning.**

Questo ci permette di capire come è meglio indirizzare budget e tempo per lo sviluppo di casi di testing.

Lo studio si concentra sull'analisi dei risultati ottenuti su due progetti open-source della Apache Software Foundation: **BookKeeper** e **Avro**.

03 Progettazione – Raccolta dei Dati

Assunzione principale: il **futuro** è simile al passato.

Jira

Tramite **Jira** estraiamo i **ticket** riferiti a **bug** risolti.

Tramite **Git** estraiamo i **commit** relativi ai **ticket** estratti.

Ora sappiamo quali **classi** sono state toccate.

03 Progettazione – Individuare i bug

Idea principale: ogni **bug** ha un ciclo di vita rappresentabile come:

Injected Version (IV): versione in cui il bug viene introdotto in una classe

Opening Version (OV): versione in cui il bug viene individuato

Fixed Version (FV): versione in cui il bug viene risolto

03 Progettazione – Proportion

Punto di partenza: una classe è difettosa dalla **IV** fino alla **FV** (esclusa).

Mentre la **OV** e la **FV** sono facilmente individuabili dai ticket di **Jira**, questo non vale per l'**IV** che spesso non è definita, come comportarci?

Idea: il tempo che intercorre tra **FV** e **OV** è proporzionale al tempo tra **FV** e **IV**.

Proportion:

$$p = \frac{FV - IV}{FV - OV} \Rightarrow IV = FV - p * (FV - OV)$$

03 Progettazione – Proportion

Utilizziamo, in base alla situazione, due diverse tecniche:

Proportion Increment

- **Quando?**

La usiamo se il numero di ticket con IV a nostra disposizione è ≥ 5.

- **Come?**

Calcolo **p** sfruttando i ticket raccolti fino a quel momento.

Proportion Cold Start:

- **Quando?**

La usiamo se il numero di Ticket con IV a nostra disposizione è < 5.

- **Come?**

Calcolo **p** basandomi su altri progetti Apache e lo imposto pari alla mediana dei valori.

03 Progettazione – Metriche

LOC: Numero di righe di codice.
Authors Number: Numero di autori della classe.
Number of Revisions: Numero di revisioni.
Touched Loc: Somma di righe aggiunte e rimosse nelle revisioni.
Total Added Lines: Numero di righe aggiunte nelle revisioni.
Average Added Lines: Numero medio di righe aggiunte nelle revisioni.
Max Added Lines: Numero massimo di righe aggiunte nelle revisioni.
Churn: Valore assoluto della differenza tra linee aggiunte e rimosse.
Max Churn: Churn massimo nelle revisioni.
Number Fix: Numero di bug fixati.
Cyclomatic Complexity*: Numero di cammini indipendenti nella classe.
Average Churn: Churn medio nelle revisioni.
Days Between Commits*: Numero di giorni tra un commit e l'altro.

* = Metriche Personalizzate

03 Progettazione – Training e Testing Set

Nel **training set** la buggyness delle classi viene determinata utilizzando solo i ticket fino alla release considerata. Le classi vengono etichettate come buggy se sono state modificate in commit associati a bug con una **injected version** precedente. Più **realistico** possibile, affetto da **snoring**.

Nel **testing**, invece, considero tutti i ticket disponibili, includendo anche informazioni su bug corretti in futuro. Più **preciso** possibile, non affetto da **snoring**.

03 Progettazione – Walk Forward

All'interno dei dati è presente la componente temporale, vogliamo quindi preservare il loro ordine cronologico. Come?

Walk Forward: tecnica **time-series**.

Per minimizzare lo **snoring**,
utilizziamo la prima metà del dataset.

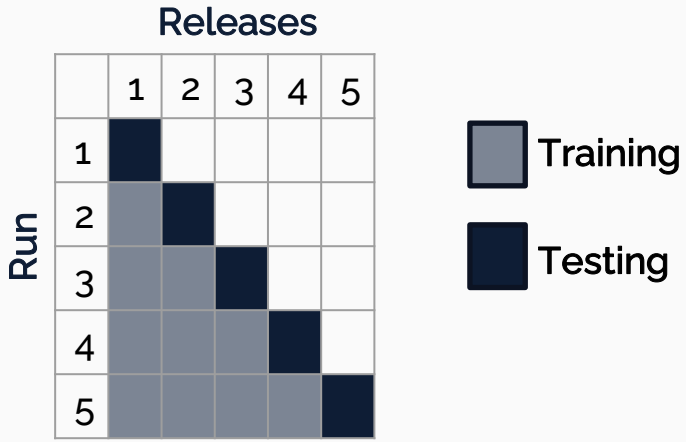

03 Progettazione – Modelli e tecniche

I **modelli** utilizzati sono:
- **Naive Bayes**
- **Ibk**
- **Random Forest**

Le **tecniche** applicate sono:
- **Cost Sensitive Classifier**
- **Feature Selection** con **Best First Backward**
- **Balancing** con **SMOTE**

Le **metriche** utilizzate per la valutazione dei **modelli** sono:
- **Precision**
- **Recall**
- **Npofb20**
- **AUC**
- **Kappa**

04 Risultati – Feature Selection

Vediamo gli **attributi** selezionati per entrambi i progetti:

Bookkeeper

```
Selected attributes: 1,2,11,13 : 4
                     LOC
                     authors_number
                     cyclomatic_complexity
                     days_between_commits
```

Avro

```
Selected attributes: 1,3,10,11,13 : 5
                     LOC
                     revisions_number
                     number_fix
                     cyclomatic_complexity
                     days_between_commits
```

In entrambi i casi, le metriche personalizzate **Complessità Ciclomatica** e **Days Between Commit** vengono selezionate.

04 Risultati Bookkeeper – AUC & Kappa

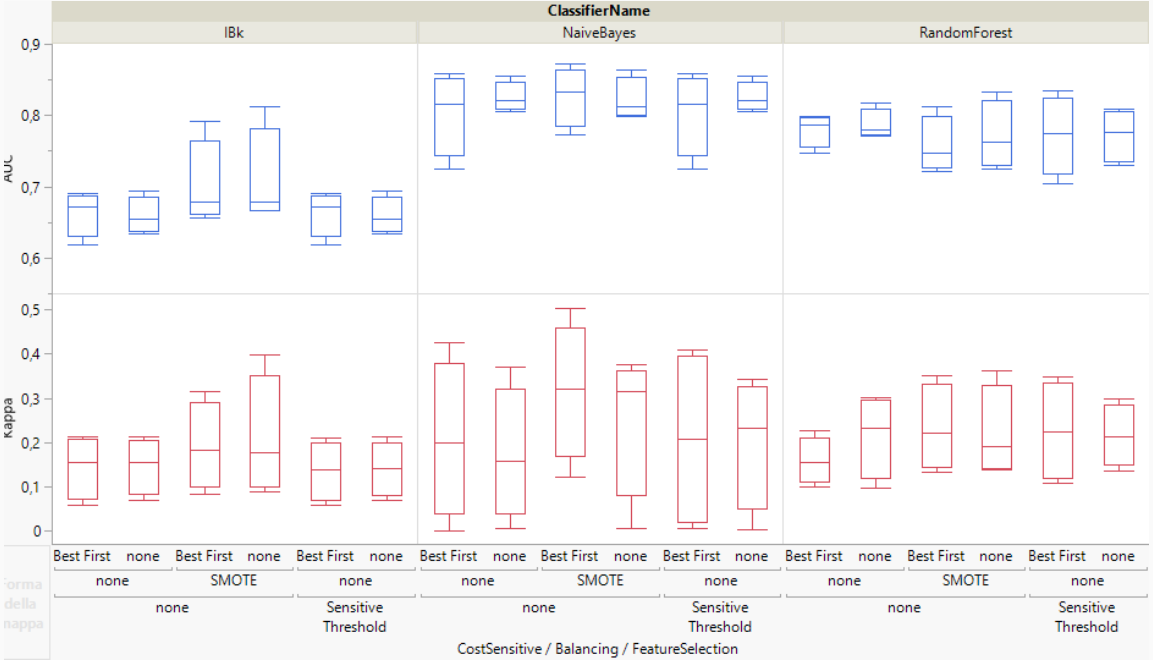

Sia per **AUC** che per **Kappa**, **Naive Bayes** risulta essere il modello con i risultati migliori, **Random Forest e Ibk**, soprattutto per **Kappa** risultano però più stabile.

04 Risultati Bookkeeper – Precision & Recall

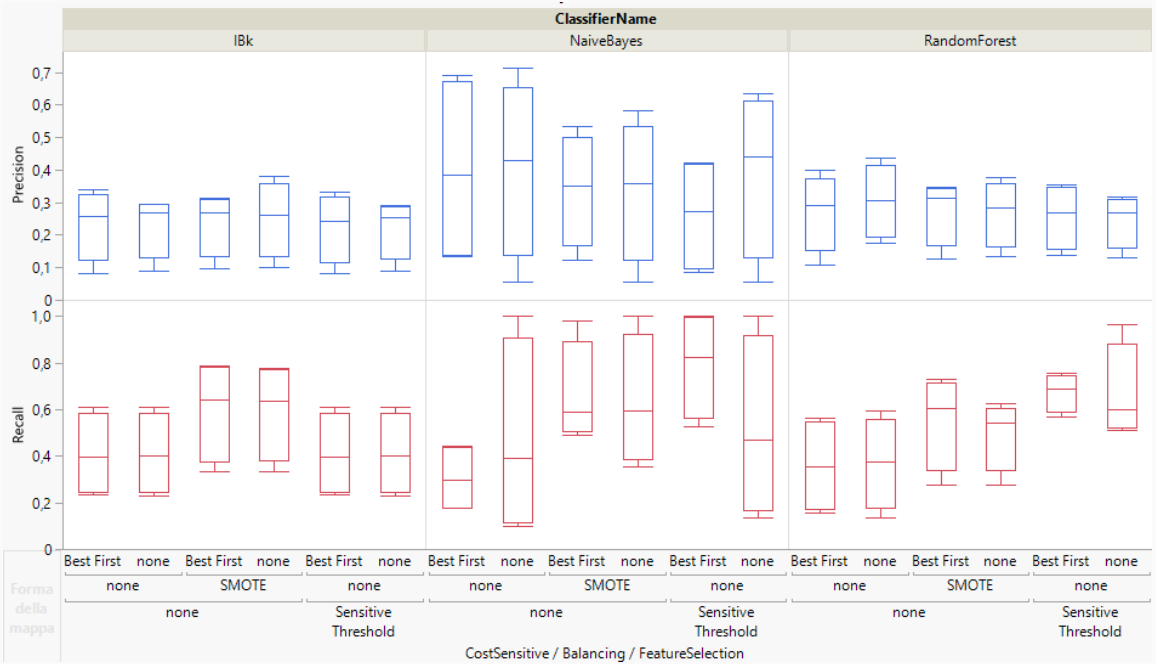

Sia per la **Precision** che per la **Recall** il miglior modello risulta essere **Naive Bayes.**

04 Risultati Bookkeeper – nPofB20

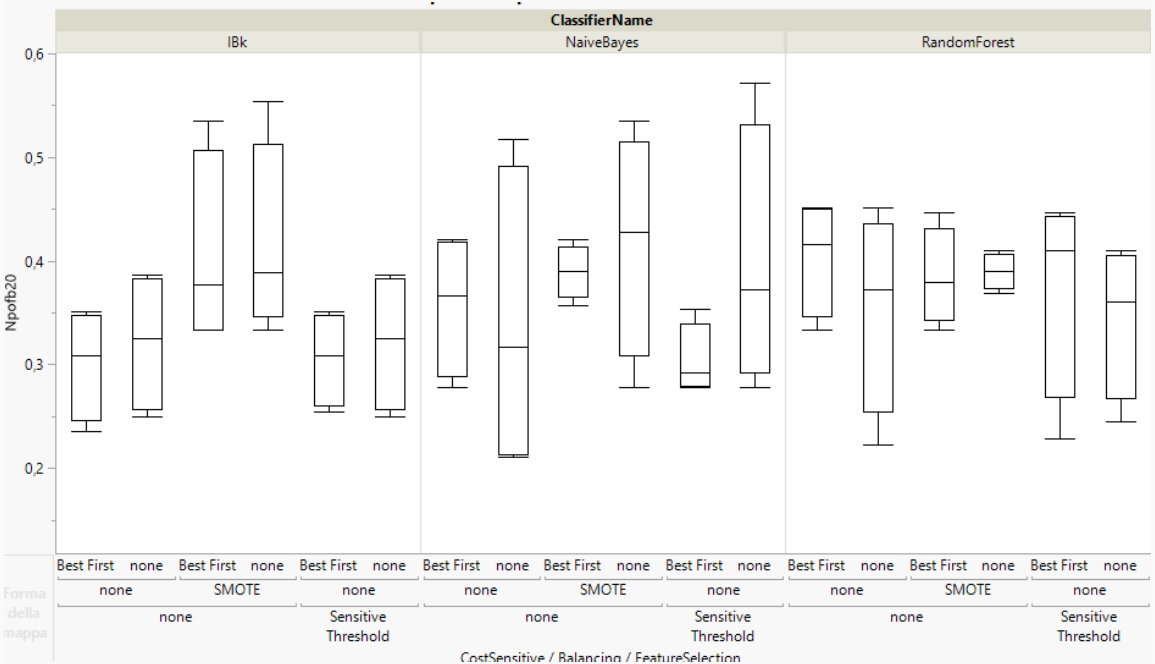

I risultati migliori vengono raggiunti da **Naive Bayes** soprattutto con l'utilizzo di **SMOTE**.

04 Risultati Avro – AUC & Kappa

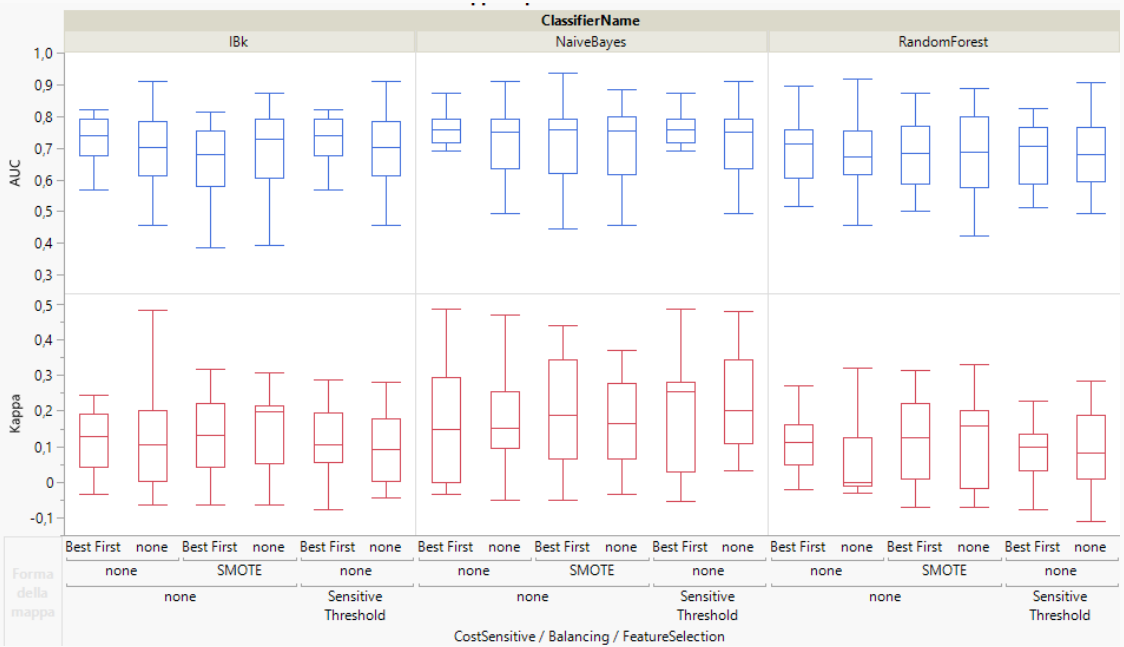

I risultati migliori vengono raggiunti, sia per **AUC** che per **Kappa**, da **Naive Bayes.**

04 Risultati Avro – Precision & Recall

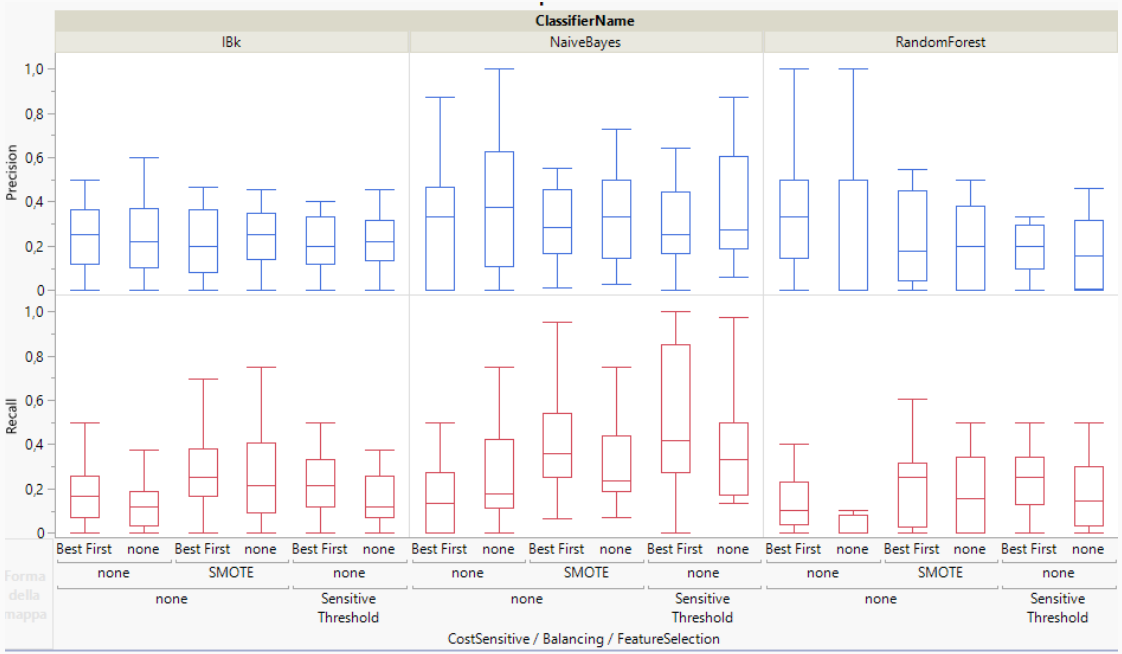

I risultati migliori, sia per **Precision** che per **Recall**, vengono raggiunti da **Naive Bayes**.

04 Risultati Avro – nPofB20

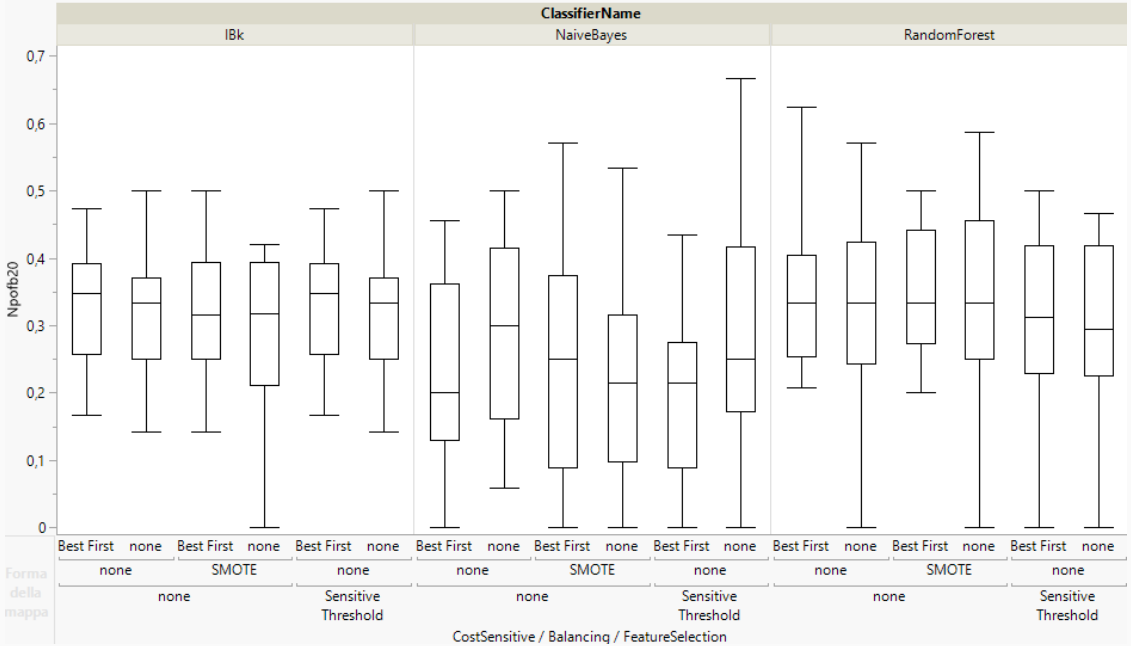

Il picco massimo viene raggiunto da **Naive Bayes**, a livello di mediana invece **Random Forest** mostra i risultati migliori

04 Risultati – Conclusioni

Sia per Bookkeeper che per Avro, **Naive Bayes** risulta essere il modello migliore, non è possibile stabilire la migliore configurazione in assoluto ma spicca la combinazione **Feature Selection** e **Sensitive Threshold** per il valore della Recall

05 Assunzioni & Minacce alla validità

- La data di apertura e chiusura del **ticket**, prelevata da **Jira**, potrebbe non essere accurata.
- I ticket che etichettiamo come **buggy**, potrebbero non esserlo.
- Le varie tecniche di proportion sono tecniche **conservative**, possono quindi sottostimare quelle che sono le performance dei vari classificatori.
- Ipotizziamo per il calcolo di **Cold Start** che i progetti Apache considerati siano simili a quelli studiati.
- La threshold considerata per il **Cold Start.**
- I ticket senza commit associati non sono stati considerati.

06 Conclusioni - Fonti

1. Paper Proportion: Leveraging the Defects Life Cycle to Label Affected Versions and Defective Classes, *Bailey Vandehei, Daniel Alencar Da Costa, Davide Falessi.*

2. Paper Snoring: The Impact of Dormant Defects on Defect Prediction: A Study of 19 Apache Projects, *Davide Falessi, AalokAhluwalia, Massimiliano Di Penta.*

3. Tempo di sviluppo testing: *https://intersog.com/blog/development/software-testing-percent-of-software-development-costs/*

4. Costo medio annuo testing: https://www.globalapptesting.com/blog/software-testing-cost

06 Conclusioni - Link

https://sonarcloud.io/project/overview?id=MarcoLor01_DatasetBuilderISW2

https://github.com/MarcoLor01/DatasetBuilderISW2

Grazie per l’attenzione!